




Detección de cáncer de mama a través de redes convolucionales




(a)



(b)



(c)



(d)

REALIZADO POR:

Marina Calero López
Lucas Manuel Herencia Solís
Juan Antonio Moreno Moguel

May 11, 2025

Resumen

Este proyecto se enmarca en la asignatura de Procesamiento de Imágenes Digitales (PID) y tiene como objetivo desarrollar un sistema que detecte el cáncer de mama mediante la identificación y comparación de células cancerígenas benignas y malignas. La metodología se basará en el uso de redes neuronales convolucionales (CNN) para analizar imágenes digitales de tejido mamario y extraer patrones característicos. Se realizan procesos de preprocesamiento y segmentación para aislar las áreas de interés, seguidos de la extracción de características específicas que permitan distinguir entre células malignas y benignas. Con este enfoque, se busca crear una herramienta de apoyo al diagnóstico clínico, que contribuya a una detección temprana y más precisa de la enfermedad. Además se realiza un estudio comparativo entre este enfoque y un enfoque más tradicional el cual aplica el clasificador K-Nearest Neighbours(KNN).

Palabras clave: cáncer de mama, redes neuronales convolucionales (CNN), células, benigno, maligno.

Índice

1. Introducción	3
2. Planteamiento del Teórico	4
2.1. Objetivos del Proyecto	4
2.2. Tecnologías Utilizadas	4
2.3. Redes Neuronales Convolucionales (CNN)	5
2.4. Autoencoder	6
2.5. K-Nearest Neighbours (KNN)	7
3. Implementación	9
3.1. Descripción del dataset	9
3.2. Arquitectura de la aplicación	9
3.3. Arquitectura CNN	10
3.4. Arquitectura KNN	12
3.5. Evaluación del Sistema	13
4. Experimentación	14
5. Manual de usuario	16
6. Conclusiones	21
7. Autoevaluación de cada miembro del equipo	22
8. Tabla de tiempos	22
Bibliografía	35

1. Introducción

El cáncer de mama es una de las principales causas de mortalidad en el mundo, habiendo sido la responsable de 670.000 muertes en 2022 siendo a su vez el tipo de cáncer más común en las mujeres según [1]. Esto provoca que durante los últimos años se haya estado realizando una labor social enorme referente a la concienciación sobre el cáncer de mama dando gran importancia a su pronta detección.



Figura 1: Cifras de la OMS [1]

Gracias a los avances en Deep Learning [2], se han desarrollado métodos innovadores para analizar imágenes histológicas y detectar el cáncer de mama. En este contexto, existen dos aproximaciones que se han estudiado en la literatura, como en el artículo **“Classification of breast cancer based on histology images using convolutional neural networks”** [3], soportada por los 445 artículos en los que se realiza un estudio entre dos enfoques.

Con el objetivo de desarrollar una aplicación capaz de detectar cáncer de mama a partir de imágenes histológicas, utilizaremos dos enfoques distintos. El *primer enfoque* se basa en una red neuronal convolucional (CNN), construida desde cero siguiendo la arquitectura de [3], que permite realizar una clasificación directa de las imágenes entre tejido benigno y maligno. El *segundo enfoque* emplea un modelo autoencoder convolucional preentrenado, obtenido desde un repositorio en línea, del cual se extrae la capa de menor dimensionalidad conocida como cuello de botella. Esta representación comprimida de las imágenes, siendo un espacio latente de 48 dimensiones, se utiliza como entrada para el algoritmo K-Nearest Neighbors (KNN), que permite clasificar nuevas muestras en función de su similitud con otras ya conocidas.

Ambos métodos son implementados y evaluados con el objetivo de comparar su rendimiento, eficiencia y aplicabilidad dentro de un sistema de diagnóstico asistido por computadora. Esta comparación busca no solo medir la precisión, sino también explorar qué tipo de arquitectura resulta más adecuada para un entorno clínico real, donde la interpretabilidad, la escalabilidad y el tiempo de respuesta son factores clave.

2. Planteamiento del Teórico

2.1. Objetivos del Proyecto

Este trabajo tiene como objetivo principal analizar y comparar diferentes metodologías de clasificación de imágenes médicas, con especial atención en la detección temprana del cáncer de mama. Para ello, se estudian tanto enfoques tradicionales de clasificación en torno a la extracción manual de características, como enfoques modernos basados en aprendizaje profundo.

Los objetivos específicos del proyecto son los siguientes:

1. **Crear** una aplicación que permita a los médicos detectar el cáncer de mama solo dando la imagen.
2. **Desarrollar** distintos modelos que permitan la clasificación binaria de las imágenes.
3. **Evaluar** el rendimiento de distintos modelos, tanto CNN en tareas de clasificación binaria como KNN.
4. **Realizar experimentación para análisis** del impacto de las técnicas de aumento de datos sobre el desempeño de los modelos.

2.2. Tecnologías Utilizadas

Para el desarrollo del proyecto se ha utilizado el lenguaje de programación **Python**[4], ampliamente adoptado en la comunidad científica por su simplicidad, legibilidad y amplio ecosistema de bibliotecas para el análisis de datos, visión por computador y aprendizaje automático.

El desarrollo de la interfaz de nuestra aplicación ha sido desarrollado utilizando **Tkinter**[5], permitiendo de esta forma una selección y visualización de resultados cómoda de las imágenes junto a su clasificación en benigna o maligna.

Entre estas bibliotecas, se ha seleccionado **TensorFlow**[6] como herramienta principal para la implementación y comparación de modelos. TensorFlow es una librería de código abierto desarrollada por Google que permite construir, entrenar y desplegar modelos de *machine learning*, especialmente redes neuronales profundas. Su flexibilidad y eficiencia lo convierten en una plataforma ideal tanto para métodos tradicionales como para arquitecturas más complejas basadas en aprendizaje profundo.

2.3. Redes Neuronales Convolucionales (CNN)

Una **Red Neuronal Convolutiva** (CNN, por sus siglas en inglés) son una clase especializada de redes neuronales artificiales diseñadas para procesar datos con una estructura de tipo cuadrícula, siendo las imágenes un ejemplo típico. A diferencia de las redes neuronales tradicionales, las CNN son capaces de aprovechar la correlación espacial entre píxeles para identificar patrones jerárquicos, lo que las convierte en una herramienta sumamente eficaz en tareas de visión por computadora, análisis biomédico, reconocimiento de voz, entre otras aplicaciones.

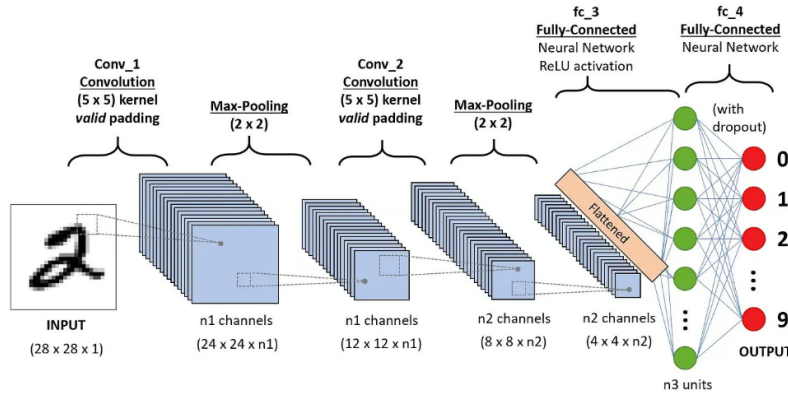


Figura 2: Capas convolucionales [7]

La arquitectura típica de una CNN está compuesta por una secuencia de capas que extraen representaciones abstractas de los datos de entrada. La primera etapa esencial en una CNN es la capa convolutiva. Esta capa aplica filtros o “*kernels*”, que recorren la imagen de entrada realizando una operación matemática denominada convolución. Cada filtro aprende a detectar características locales específicas, como formas, texturas o regiones de contraste. El resultado de esta operación es un conjunto de mapas de activación que reflejan la presencia de determinadas características en distintas regiones de la imagen [8].

Tras la convolución, se aplica comúnmente una función de activación no lineal. La más utilizada en redes modernas es la función **ReLU** (Rectified Linear Unit), que introduce no linealidades en el modelo al anular los valores negativos. Esta operación permite a la red aprender representaciones más complejas que no podrían modelarse únicamente con funciones lineales [9]. Sin embargo, una limitación conocida de ReLU es que, si las entradas son negativas, la función devuelve cero, lo que puede causar que algunas neuronas dejen de actualizarse durante el entrenamiento, un fenómeno conocido como el “*problema de las neuronas muertas*”. Para mitigar esta situación, se utiliza con frecuencia una variante llamada **Leaky ReLU**, la cual modifica la función para que permita un pequeño gradiente también en la región negativa. Matemáticamente, se define como:

$$\text{LeakyReLU}(x) = \begin{cases} x & \text{para } x > 0 \\ \alpha x & \text{para } x \leq 0 \end{cases}, \quad \alpha = 0,01 \text{ (valor típico)}$$

. Esta modificación mejora la capacidad de aprendizaje de la red al evitar que las neuronas queden inactivas de manera permanente [10].

Posteriormente, se emplea una capa de agrupamiento, o pooling, que tiene como objetivo reducir la dimensionalidad espacial de los mapas de activación. Esta reducción permite disminuir el número de parámetros y operaciones computacionales, al tiempo que se mantiene la información más relevante. El agrupamiento también aporta robustez frente a pequeñas variaciones o distorsiones en la entrada [11].

Las características extraídas a lo largo de las capas anteriores son finalmente procesadas por una o más capas completamente conectadas, también conocidas como *fully connected layers*. En esta etapa, cada neurona está conectada a todas las salidas de la capa anterior, y la red combina las representaciones obtenidas para realizar una inferencia basada en el conocimiento aprendido. Esta parte del modelo funciona como un clasificador que transforma las representaciones espaciales en una predicción final.

La red concluye con una capa de salida que depende del tipo de problema que se desea resolver. En tareas de clasificación multiclase, se utiliza generalmente una función *softmax* que devuelve una distribución de probabilidad sobre las clases. Para problemas de clasificación binaria, la función sigmoide es comúnmente empleada, ya que proporciona una probabilidad entre 0 y 1 que indica la pertenencia de la entrada a una de las dos clases posibles [12].

El proceso de aprendizaje de una CNN se realiza mediante retropropagación, un algoritmo que ajusta los parámetros de la red a partir del error entre las predicciones y las etiquetas verdaderas. Este error se cuantifica mediante una función de pérdida, siendo la entropía cruzada una de las más utilizadas en problemas de clasificación. A su vez, algoritmos de optimización como Adam o Stochastic Gradient Descent (**SGD**) se encargan de actualizar los pesos del modelo en cada iteración, guiando el proceso de entrenamiento hacia una solución que minimice la pérdida [13], [14].

En el apartado de Implementación se describe detalladamente como se ha construido la CNN usada.

2.4. Autoencoder

La estructura básica de un autoencoder consta de dos componentes principales (como muestra la Figura 3): un codificador (**encoder**) y un decodificador (**decoder**). El codificador actúa de manera análoga a las primeras capas de una CNN, tomando la entrada y transformándose progresivamente en una representación de menor dimensionalidad. Esta representación comprimida se denomina **espacio latente**, y constituye el núcleo informativo del autoencoder. Es en este espacio donde se concentran las características más relevantes de la entrada, de manera que, incluso tras eliminar redundancias o ruido, se retiene la información esencial [15].

En aplicaciones que integran CNN con autoencoders frecuentemente llamadas **convolutional autoencoders**, el codificador suele incluir capas convolucionales que permiten aprovechar las estructuras espaciales locales, de forma similar a una CNN estándar. Este diseño no solo reduce la dimensionalidad, sino que también conserva información espacial crítica para la reconstrucción posterior [16].

El **espacio latente** cumple una función crucial: actúa como un cuello de botella que obliga al modelo a aprender una codificación eficiente. A diferencia de una simple reducción de tamaño, esta compresión es aprendida automáticamente por la red en función de su capacidad para reconstruir los datos de entrada. Por esta razón, la calidad de la representación latente determina directamente el rendimiento del autoencoder. Si la codificación es adecuada, el decodificador será capaz de reconstruir la entrada con alta fidelidad, incluso cuando se utilice una representación mucho más compacta [17], [18].

El **decodificador**, por su parte, invierte el proceso realizado por el codificador. A partir del espacio latente, genera una reconstrucción de la entrada original utilizando capas que gradualmente expanden la dimensionalidad. En autoencoders convolucionales, esta expansión se realiza mediante **capas convolucionales transpuestas** o **upsampling**, que permiten reconstruir las estructuras espaciales originales. A diferencia del codificador, que se enfoca en extraer características, el decodificador se centra en aprender cómo esas características pueden combinarse para generar una salida coherente [16].




Figura 3: Autoencoder[19]

2.5. K-Nearest Neighbours (KNN)

El algoritmo **K-Nearest Neighbors** (k-NN) es uno de los métodos más simples y efectivos dentro del aprendizaje automático supervisado. A diferencia de modelos como las redes neuronales, que requieren un proceso de entrenamiento explícito, el k-NN es un método perezoso (*lazy learner*), es decir, no construye un modelo a priori, sino que realiza la clasificación directamente a partir de los datos de entrenamiento disponibles [20].

La idea fundamental detrás del k-NN es que una instancia se clasifica en función de las clases mayoritarias de sus **k vecinos más cercanos** en el espacio de características. Para determinar estos vecinos, se calcula la distancia entre la instancia a clasificar y cada punto del conjunto de entrenamiento, siendo la distancia euclidiana la medida más común, aunque otras como la distancia de Manhattan o la distancia de Mahalanobis también son utilizadas dependiendo del contexto del problema [21].




Figura 4: K-Nearest Neighbours [22]

En el marco de arquitecturas más complejas como las **Redes Convolucionales** (CNN) o los autoencoders, el k-NN se utiliza frecuentemente como clasificador final sobre las representaciones extraídas por estas redes. Por ejemplo, en lugar de utilizar capas completamente conectadas o *softmax* para la **clasificación final**, es posible aplicar k-NN sobre el **espacio latente** de un autoencoder o sobre los mapas de activación extraídos por las capas convolucionales. Esta estrategia es particularmente útil cuando se desea evaluar la **capacidad discriminativa de la representación aprendida**, independiente de la arquitectura del clasificador [23].

Una de las principales ventajas del k-NN en estos contextos es su **robustez** y **simplicidad**. No requiere entrenamiento adicional una vez se ha obtenido la representación latente, y su rendimiento depende únicamente de la calidad del espacio de características. Esto lo convierte en una herramienta ideal para comparar distintas representaciones, evaluar embeddings o realizar pruebas rápidas sin necesidad de reentrenar redes profunda [24].

Sin embargo, KNN también presenta limitaciones. Su eficiencia computacional disminuye cuando el número de muestras o la dimensionalidad del espacio de características es muy alta un problema conocido como la "*maldición de la dimensionalidad*". Por ello, su uso suele estar precedido por una etapa de reducción de dimensionalidad o extracción de características, como las proporcionadas por autoencoders o CNN, que ayudan a preservar solo la información más relevante [25].

3. Implementación

El desarrollo de este proyecto se fundamenta en el uso de técnicas de aprendizaje automático y profundo para la clasificación de imágenes histológicas de cáncer de mama. Con el objetivo de comparar el rendimiento entre distintos enfoques, se han implementado y entrenado dos tipos de modelos: el primero, una CNN, y el segundo, un autoencoder del cual se obtiene la capa de menor dimensionalidad o *bottleneck* y usando después un clasificador K-Nearest neighbours para obtener el resultado. Ambos modelos han sido entrenados utilizando un conjunto de imágenes histológicas públicamente disponibles.

3.1. Descripción del dataset

Para el desarrollo de este proyecto se utilizó el **dataset de imágenes histológicas de cáncer de mama BreaKHis** [26], asociado al trabajo de [3], ampliamente reconocido en la literatura científica por su utilidad en investigaciones de diagnóstico asistido por computadora en cáncer de mama. Este dataset contiene un total de 9,109 imágenes histopatológicas de tejido tumoral mamario, recolectadas de 82 pacientes en [27].

Las muestras se obtuvieron mediante biopsia excisional (**SOB**), también conocida como mastectomía parcial, un procedimiento quirúrgico realizado bajo anestesia general que permite extraer una porción significativa de tejido para su análisis. Las imágenes fueron teñidas con hematoxilina y eosina (H&E), y capturadas mediante un microscopio óptico en cuatro niveles de aumento: 40X, 100X, 200X y 400X. Todas las imágenes presentan una resolución de 700×460 píxeles, están codificadas en formato PNG, y utilizan un modelo de color RGB de 3 canales a 8 bits por canal.

BreaKHis está dividido en dos clases principales: tumores **benignos** (2,480 imágenes) y tumores **malignos** (5,429 imágenes). Cada una de estas clases se subdivide en cuatro tipos histológicos distintos, basados en la morfología observada al microscopio:

- **Benignos:** Adenosis (A), Fibroadenoma (F), Tumor filoides (PT) y Adenoma tubular (TA).
- **Malignos:** Carcinoma ductal (DC), Carcinoma lobulillar (LC), Carcinoma mucinoso (MC) y Carcinoma papilar (PC).

En esta investigación se utilizó una versión del dataset disponible públicamente en [26], la cual se encuentra organizada de forma estructurada para entrenamiento, validación y evaluación, dividiéndose a su vez en magnificación y tipo, lo que facilitó la gestión y preparación de los datos para el entrenamiento de los modelos.

3.2. Arquitectura de la aplicación

Esta aplicación de escritorio ha sido desarrollada con Python utilizando la biblioteca **Tkinter** y la extensión **tkinterdnd2** para soporte de arrastrar y soltar. Está diseñada

para facilitar el análisis automatizado de imágenes microscópicas de tejidos mamarios, permitiendo la clasificación entre lesiones benignas y malignas mediante modelos de machine learning. La interfaz ofrece una experiencia visual amigable y funcional para profesionales o investigadores del área médica.

Principales funcionalidades:

1. **Carga de imágenes eficiente:** Permite seleccionar múltiples imágenes desde el sistema de archivos o mediante arrastrar y soltar directamente sobre el área de previsualización. Soporta formatos como PNG, JPG, JPEG, BMP y GIF.
2. **Previsualización y navegación:** Muestra una imagen ampliada de la muestra seleccionada y un carrito con miniaturas generadas automáticamente, facilitando la revisión manual. Se utiliza `PIL.Image` para procesar imágenes y `ImageTk.PhotoImage` para su integración en la GUI.
3. **Selector de modelo de análisis:** Incluye un desplegable con modelos disponibles: KNN y CNN, con variantes según niveles de aumento (40x, 100x, 200x, 400x), permitiendo seleccionar el tipo de entrenamiento más adecuado según la resolución de las imágenes.
4. **Ejecución y control del análisis:** Los análisis se realizan de forma secuencial mediante hilos (`threading.Thread`) para mantener la interfaz fluida. Los modelos son invocados a través de funciones importadas desde los módulos `knn.py` y `cnn.py`, que devuelven una predicción y un color representativo.
5. **Visualización de resultados y estadísticas:** Para cada imagen se muestra el resultado (Benigno/Maligno) con retroalimentación visual (círculo coloreado) y se actualizan las estadísticas globales: cantidad total de imágenes, benignas y malignas. Se incluye también una barra de progreso (`ttk.Progressbar`).
6. **Gestión del análisis:** Se ofrecen botones para iniciar, pausar/reanudar y eliminar las imágenes seleccionadas. Los resultados se limpian automáticamente al cargar nuevas imágenes o al reiniciar el análisis.

3.3. Arquitectura CNN

Para la implementación del modelo CNN se ha seguido la arquitectura descrita en el artículo “*Classification of Breast Cancer Based on Histology Images Using Convolutional Neural Networks*” [3], en el cual se desarrolla una red neuronal convolucional (CNN) especialmente diseñada para abordar el desafío de clasificar imágenes histológicas de tejido mamario teñidas con hematoxilina y eosina (H&E).

El modelo desarrollado presenta una estructura jerárquica compuesta por 5 capas convolucionales, seguidas de dos capas completamente conectadas y una capa de salida con activación *softmax*. Cada capa convolucional aplica filtros (también denominados *kernels*) de tamaño 3×3 , que se deslizan sobre la imagen para detectar patrones locales como bordes, texturas o regiones celulares características. En detalle, la *primera* capa genera 64 mapas de características; la *segunda*, 96; la *tercera*, 128; y tanto la *cuarta* como la *quinta*, 256 mapas. Estas capas permiten una extracción progresiva de características, pasando

de representaciones simples a otras más abstractas y complejas.

Tras las capas convolucionales, se emplean operaciones de **max pooling** en la primera, segunda y quinta capa, utilizando ventanas de 3×3 con un stride de 2. El *max pooling* selecciona el valor máximo dentro de cada región, reduciendo así la resolución espacial de las representaciones internas y proporcionando invariancia ante pequeñas traslaciones. El *stride*, o paso de desplazamiento, controla cuántos píxeles se avanza al aplicar esta operación; un valor de 2 reduce la dimensionalidad de forma más agresiva. Las capas tercera y cuarta no aplican *pooling*, lo cual permite conservar la resolución espacial de las características extraídas, favoreciendo una mayor sensibilidad a detalles finos del tejido.

Todas las capas convolucionales están seguidas por una función de activación ReLU (**Rectified Linear Unit**), definida como:

$$f(x) = \max(0, x) \quad (1)$$

, que introduce no linealidad en el modelo y mejora la eficiencia del entrenamiento al evitar el problema del desvanecimiento del gradiente. Los pesos de estas capas se inicializan a partir de una distribución normal con desviación estándar pequeña (0,01), y se aplica regularización L2 (*weight decay*) con un coeficiente de penalización de $\lambda = 10^{-3}$, lo cual ayuda a evitar el sobreajuste penalizando los pesos excesivamente grandes.

A la salida de las capas convolucionales, los mapas de activación se aplanan mediante una capa *Flatten*, que convierte las matrices tridimensionales en un vector unidimensional para conectarlas con las capas densas. La primera capa densa contiene 2000 neuronas con activación ReLU y se acompaña de una capa *Dropout* con una probabilidad de desactivación del 50 %. Esta técnica consiste en “apagar” aleatoriamente la mitad de las neuronas durante el entrenamiento, reduciendo así la dependencia entre unidades y mejorando la capacidad de generalización del modelo. Finalmente, la segunda capa densa contiene tantas neuronas como clases en el problema (en este caso, dos) y emplea una activación *softmax*, que convierte las salidas en una distribución de probabilidad sobre las clases, facilitando la clasificación final.

El modelo se entrena utilizando el algoritmo Stochastic Gradient Descent (SGD), que actualiza los pesos en función de pequeños subconjuntos aleatorios de datos (*minibatches*), en lugar de utilizar todo el conjunto de entrenamiento, lo que acelera el proceso y mejora la generalización. La tasa de aprendizaje se fija inicialmente en 0,001, controlando la magnitud de los ajustes en los pesos, y se aplica un *momentum* de 0,9, que introduce una memoria del gradiente pasado para suavizar las oscilaciones y acelerar la convergencia. La función de pérdida utilizada es categorical *crossentropy*, adecuada para problemas de clasificación multiclase con etiquetas codificadas en formato *one-hot*.

Finalmente, el modelo puede entrenarse sobre imágenes con distintas magnificaciones o bien utilizando un conjunto combinado, y se proporciona la funcionalidad para guardar tanto el modelo completo como únicamente los pesos aprendidos. Esta flexibilidad resulta útil tanto para entrenamientos posteriores como para su integración en entornos clínicos.

Al finalizar el proceso de entrenamiento, se generan 5 archivos con el mismo modelos y con los pesos obtenidos tras el entrenamiento, cada uno de estos se ha entrenado con

un conjunto de datos distintos, ya sea con todos los datos, con los de magnificación 40X, 100X, 200X o 400X.

3.4. Arquitectura KNN

Se emplea un autoencoder convolucional basado en el artículo [28] para la recuperación de imágenes histológicas de cáncer de mama. Este modelo, compuesto por un codificador y un decodificador, extrae representaciones latentes útiles para clasificación o búsqueda por similitud. Se entrena minimizando el error de reconstrucción mediante optimizadores como SGD o Adam, utilizando conjuntos de entrenamiento y validación para evitar el sobreajuste. Este tipo de red se caracteriza por una estructura simétrica compuesta por dos partes principales: el codificador y el decodificador..

1. **Codificación (Encoder):** cse encarga de transformar la imagen de entrada en una representación latente de baja dimensionalidad mediante una serie de capas convolucionales con filtros de tamaño 3×3 y funciones de activación ReLU. Estas capas están acompañadas por operaciones de max pooling que reducen progresivamente la resolución espacial, extrayendo características jerárquicas de alto nivel. El resultado es un vector latente de **48 dimensiones**, correspondiente al cuello de botella del modelo, que encapsula la información visual más relevante de la imagen.
2. **Decodificación (Decoder):** intenta reconstruir la imagen original a partir de esta representación comprimida, utilizando capas de upsampling y convolucionales dispuestas simétricamente respecto al codificador. El entrenamiento del autoencoder se realiza minimizando el error cuadrático medio (MSE) entre la imagen de entrada y su reconstrucción, obligando así al modelo a aprender una codificación eficiente y significativa.

Tras el proceso de extracción de características mediante el autoencoder convolucional, cada imagen del conjunto de datos es transformada en un vector latente de 48 dimensiones, que representa las características más relevantes de la imagen histológica en un espacio comprimido. Estos vectores latentes, junto con su etiqueta de clase correspondiente (por ejemplo, benigno o maligno), se almacenan en un archivo **JSON** que actúa como base de datos para el sistema de clasificación.

Para realizar la clasificación de una nueva imagen, se sigue el siguiente procedimiento:

1. **Extracción del vector latente:** La imagen de entrada se procesa a través del codificador previamente entrenado, extrayendo su correspondiente vector de características.
2. **Cálculo de distancias:** Se calcula la **distancia euclidiana** entre este vector y todos los vectores almacenados en el conjunto indexado. La distancia euclídea entre dos vectores x e y se define como:

$$d(x, y) = \sqrt{\sum_{i=1} (x_i - y_i)^2} \quad (2)$$

3. **Selección de los vecinos más cercanos:** Una vez calculadas todas las distancias, se seleccionan los **k vectores más cercanos**, siendo $k=5$ en esta implementación. Estos representan las imágenes más similares en el espacio latente.
4. **Clasificación por mayoría:** Se toma la clase más común entre los cinco vectores más próximos, y esta se asigna como la **predicción final** para la imagen de entrada.

Este enfoque no requiere un entrenamiento explícito del clasificador, ya que el método k-NN funciona de forma **perezosa** (lazy learning) y opera directamente sobre las instancias almacenadas. Gracias a la alta calidad de las características extraídas por el autoencoder, el sistema logra clasificaciones precisas sin necesidad de arquitecturas más complejas.

3.5. Evaluación del Sistema

Los modelos fueron evaluados mediante un conjunto de métricas de clasificación binaria, entendiendo que los benignos serán los casos negativos y los malignos los casos positivos:

1. **Precisión (accuracy):** mide la proporción de predicciones correctas respecto al total de muestras evaluadas. Se calcula como:

$$\text{accuracy} = \frac{VP + VN}{VP + VN + FP + FN} \quad (3)$$

2. **Sensibilidad (recall):** evalúa la capacidad del modelo para identificar correctamente las muestras positivas. Se calcula como:

$$\text{recall} = \frac{VP}{VP + FN} \quad (4)$$

3. **Precisión (precision):** cuantifica la proporción de muestras clasificadas como positivas que realmente lo son. Se calcula como:

$$\text{precision} = \frac{VP}{VP + FP} \quad (5)$$

4. **F1 Score:** proporciona una medida balanceada entre la precisión y la sensibilidad, siendo especialmente útil en contextos donde existe un desequilibrio entre clases. Se calcula como:

$$F1 = 2 \cdot \frac{\text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}} \quad (6)$$

Estas métricas fueron calculadas de forma individual para cada uno de los modelos entrenados, lo que permitió realizar un análisis cuantitativo del impacto que tiene el tipo de arquitectura como *K-Nearest Neighbors* (KNN) y *Convolutional Neural Networks* (CNN) sobre el rendimiento en la tarea de clasificación.

Adicionalmente, se evaluó la influencia de distintos niveles de *data augmentation* aplicados a las imágenes de entrada, tanto para KNN como con CNN con el fin de observar cómo afectan la capacidad de generalización de los modelos.

Como parte del trabajo, se llevó a cabo una experimentación adicional orientada a evaluar el impacto de una integración más profunda entre los enfoques basados en KNN y CNN. En esta etapa, se creó un sistema de almacenamiento que registró todas las representaciones extraídas de las imágenes mediante el modelo KNN, sin restricciones en cuanto a la dimensión o amplitud de dichas características. Paralelamente, se entrenó un modelo CNN utilizando la totalidad del conjunto de imágenes disponibles, y se extrajeron los pesos resultantes tras el entrenamiento completo del modelo. Esta experimentación se realizó con el fin de observar qué resultados podían obtenerse al disponer de ambas fuentes de representación, y explorar su posible utilidad en tareas de clasificación médica.

4. Experimentación

Para llevar a cabo la experimentación, se realizaron pruebas sobre un conjunto de datos al que se le aplicará *data augmentation* con el objetivo de evaluar la robustez y capacidad de generalización de los modelos. Las técnicas de aumento de datos incluirán transformaciones como rotaciones de un rango entre -30° a 30° y modificaciones en la intensidad de las imágenes, con un factor de entre 0,7 (oscurece) a 1,3 (ilumina), simulando variaciones realistas que podrían encontrarse en escenarios del mundo real. Esto permitirá analizar cómo afecta la variabilidad de entrada al rendimiento de los modelos evaluados.

En esta etapa, se llevará a cabo una comparación de rendimiento entre dos enfoques de clasificación: una red neuronal convolucional (*CNN*) entrenada sobre cada variedad de las imágenes aumentadas y un entrenamiento con todas las imágenes en global, y un modelo *K-Nearest Neighbors* (*KNN*) diseñado de forma personalizada para cada uno de las posibles variaciones de imágenes respecto a su aumento. Esta comparación permitirá observar las diferencias entre un enfoque basado en aprendizaje profundo y otro basado en métodos clásicos de aprendizaje supervisado, en cuanto a métricas de *precisión*, *recall* y *F1-score*.

A continuación se muestran los resultados de las pruebas realizadas para entender de mejor manera la robustez y adaptabilidad de los distintos modelos:




Figura 5: Métrica para CNN y KNN al ser probados con el dataset completo y con el dataset aumentado.




Figura 6: Métrica para CNN y KNN al ser probados con el dataset de 40X y con el dataset aumentado.

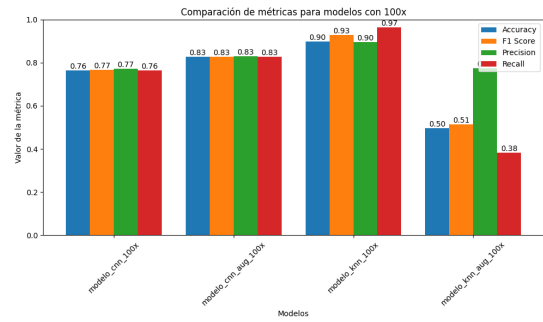


Figura 7: Métrica para CNN y KNN al ser probados con el dataset de 100X y con el dataset aumentado.




Figura 8: Métrica para CNN y KNN al ser probados con el dataset de 200X y con el dataset aumentado.

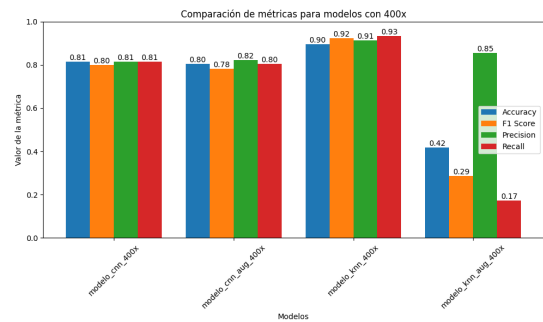


Figura 9: Métrica para CNN y KNN al ser probados con el dataset de 400X y con el dataset aumentado.

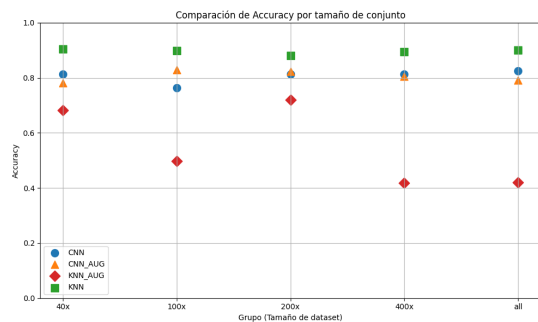


Figura 10: Comparación de accuracy




Figura 11: Comparación de precision

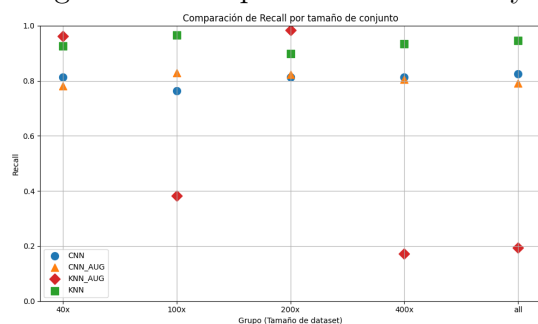


Figura 12: Comparación de Recall

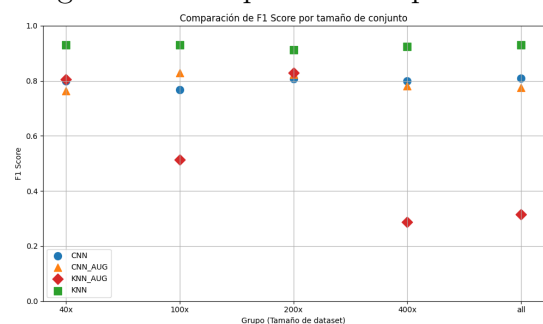


Figura 13: Comparación de F1 Score

En la presente experimentación, se evaluaron de manera sistemática los resultados obtenidos por los distintos modelos a través de dos tipos de representaciones gráficas. El primer conjunto de figuras (5, 6, 7, 8, 9) permite comparar las métricas clave de evaluación (Accuracy, F1 Score, Precision y Recall) entre los modelos entrenados sobre un mismo conjunto de datos, abarcando cinco configuraciones distintas según la magnificación de las imágenes. En estas comparaciones se incluyen cuatro variantes experimentales: CNN sin aumento de datos, para analizar su rendimiento sobre datos similares al entrenamiento; CNN con aumento, para evaluar su capacidad de adaptación ante transformaciones visuales; KNN sin aumento, que permite medir su rendimiento en un entorno cerrado; y KNN con aumento, que sirve para analizar su robustez ante variaciones visuales no vistas durante la generación del espacio latente.

El segundo conjunto de gráficas(10, 11, 12, 13) invierte el enfoque, mostrando la evolución de una única métrica a través de todos los modelos disponibles, lo que facilita el análisis transversal del comportamiento de cada enfoque respecto a una métrica concreta.

De la interpretación de estas gráficas se desprenden varios aspectos relevantes:

- En primer lugar, se observa la notable estabilidad del modelo CNN, cuyas métricas se mantienen relativamente constantes independientemente del tamaño del conjunto de datos o de la magnificación, lo que indica una buena capacidad de generalización. Esto refuerza la idoneidad del modelo CNN en contextos clínicos donde la variabilidad de las muestras puede ser alta.
- En segundo lugar, se constata que el enfoque basado en autoencoder + k-NN obtiene un rendimiento superior al del modelo CNN cuando se trabaja sobre datos no aumentados, lo que sugiere una gran eficacia del sistema en contextos cerrados o controlados. Sin embargo, esta ventaja desaparece bruscamente al aplicar técnicas de data augmentation. Las métricas del KNN se degradan significativamente en presencia de transformaciones geométricas o visuales, revelando una importante fragilidad del sistema ante cambios en los datos de entrada.

Esta degradación se atribuye a la alteración de los vectores latentes generados por el autoencoder cuando se introducen variaciones visuales, ya que al introducir cambios visuales el vector latente a analizar por el k-NN es distinto al vector original por lo que puede dar otro valor de clasificación. A diferencia de la CNN, que ajusta sus parámetros internos durante el entrenamiento para acomodar estas variaciones, el sistema basado en k-NN no posee un mecanismo de adaptación, lo que conduce a una pérdida de coherencia en el espacio latente y, por ende, a un descenso en la precisión de la clasificación.

5. Manual de usuario

Esta herramienta permite cargar una imagen desde el dispositivo y realizar un análisis para determinar si corresponde a un caso **benigno** o **maligno**. Los pasos a seguir son los siguientes:

Paso 1: Seleccionar una Imagen

Opción 1: Cargar por Ruta

- Haz clic en el botón **Seleccionar Imágenes**.
- Navega por tus carpetas y selecciona las imágenes que desees analizar.
- Las imágenes seleccionadas aparecerán en el panel de previsualización.

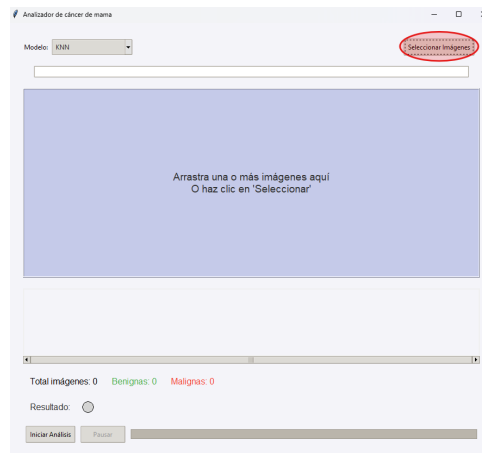


Figura 14: Botón para la carga de imágenes

Opción 2: Arrastrar y Soltar

- Puedes arrastrar la imagen directamente desde tu explorador de archivos y soltarla en el área indicada de la aplicación.
- Las imágenes se cargarán automáticamente en la aplicación.

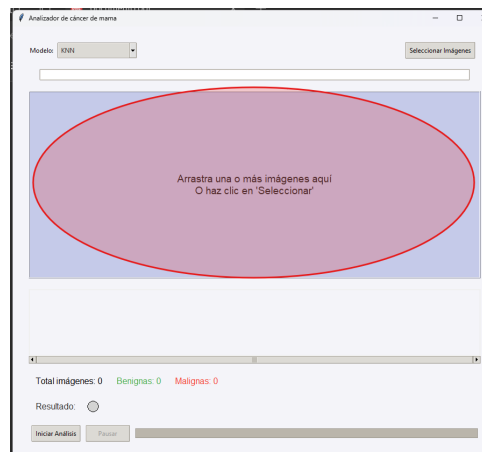


Figura 15: Pantalla de carga de imágenes

Paso 2: Seleccionar el Modelo

- Una vez que hayas cargado la imagen correctamente, tiene que seleccionar el modelo.
- Arriba a la izquierda de la pantalla, verás un menú desplegable con las opciones de modelos disponibles.

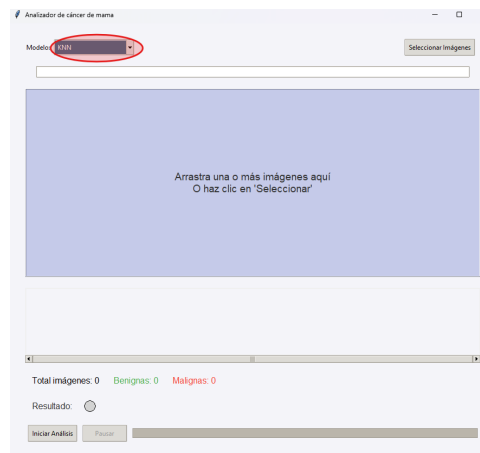


Figura 16: Menú desplegable para seleccionar el modelo

Paso 3: Iniciar el Análisis

- Una vez que hayas cargado la imagen correctamente, haz clic en el botón **Analizar**.
- La aplicación procesará la imagen y mostrará si corresponde a un caso maligno o benigno.

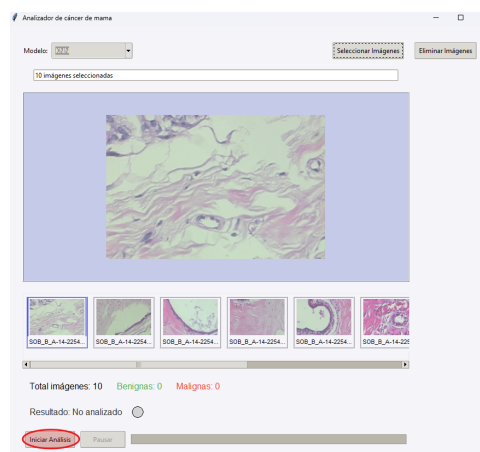


Figura 17: Botón para iniciar el análisis

Otras opciones:

- Puedes pausar el análisis en cualquier momento haciendo clic en el botón **Pausar**.

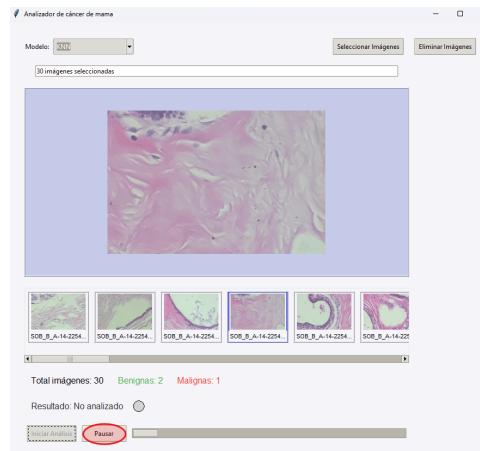


Figura 18: Botón para pausar el análisis

- O si bien lo desea puede reanudar el análisis haciendo clic en el botón **Reanudar**.

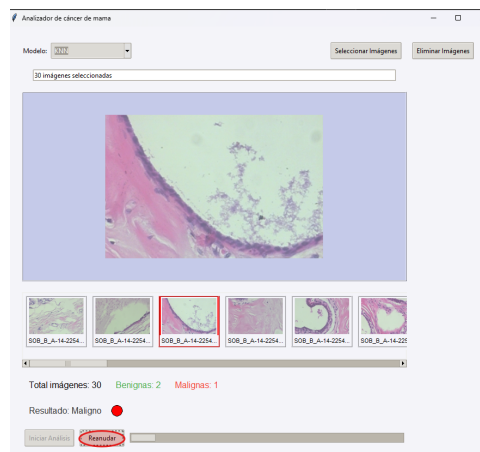


Figura 19: Botón para reanudar el análisis

Paso 4: Ver el Resultado

- Después de un breve momento, se mostrará el resultado en pantalla.
- Si la imagen es **benigna**, se mostrará un mensaje y un círculo indicador en color **verde**.
- Si la imagen es **maligna**, se mostrará un mensaje y un círculo indicador en color **rojo**.

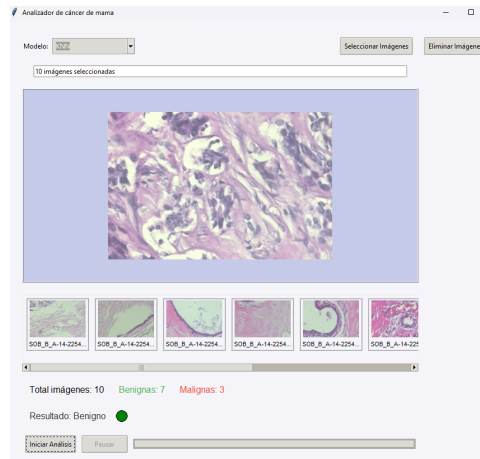


Figura 20: Pantalla de resultado del análisis

Paso 5: Realizar Nuevos Análisis

- Puede eliminar los resultados dados haciendo clic al boton de **Eliminar** o bien puede volver a cargar otras imágenes haciendo clic nuevamente en el botón **Seleccionar** o arrastrándolas directamente.
- El proceso de análisis es el mismo para cada imagen que cargues.

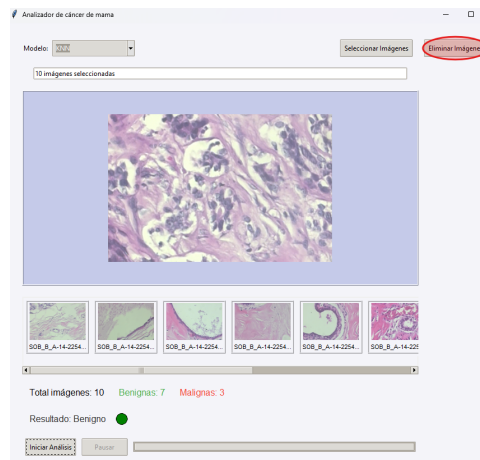


Figura 21: Botón para eliminar imágenes

6. Conclusiones

Este trabajo ha comparado *dos enfoques* para la clasificación de imágenes histológicas de cáncer de mama: un modelo de red neuronal convolucional (**CNN**) entrenado de forma supervisada, y un sistema basado en autoencoders convolucionales combinados con el algoritmo k-Nearest Neighbors (**k-NN**).

El modelo CNN ha demostrado ser robusto, estable y eficaz, alcanzando hasta un 82.8% de precisión con técnicas de *data augmentation*. Esta capacidad de adaptarse a variaciones visuales como cambios en iluminación, orientación o resolución lo hace especialmente adecuado para su uso en situaciones reales, donde las imágenes histológicas pueden variar sustancialmente según el paciente, el escáner o el protocolo de adquisición. Además, su rendimiento ha sido consistente a través de diferentes magnificaciones y configuraciones de entrenamiento, lo que refuerza su fiabilidad como herramienta de soporte en entornos clínicos.

En contraste, el enfoque con autoencoder y k-NN mostró un rendimiento excelente en condiciones controladas, llegando hasta un 90.1% de precisión cuando los datos de prueba eran similares a los de entrenamiento. Sin embargo, su desempeño se degradó de forma significativa al introducir transformaciones visuales, con caídas abruptas en precisión y otras métricas clave. Este fenómeno se explica por el cambio en los vectores latentes generados por el autoencoder cuando se alteran visualmente las imágenes debido a que los cambios visuales alteran los vectores latentes del autoencoder, y al depender de un clasificador externo como k-NN, sin capacidad de adaptación, se pierde coherencia y se reduce la fiabilidad del sistema.

Este comportamiento expone una limitación crítica del método k-NN en contextos médicos: la falta de adaptabilidad ante datos no vistos o alterados, lo que puede traducirse en errores diagnósticos si no se gestiona adecuadamente. En un entorno médico, donde las decisiones automáticas pueden tener implicaciones directas sobre la vida del paciente, es indispensable contar con modelos que no solo ofrezcan buenas métricas en laboratorio, sino que mantengan su rendimiento ante variaciones reales y potencialmente imprevistas.

Por tanto, el modelo CNN se perfila como la opción más adecuada para aplicaciones clínicas, ofreciendo un balance óptimo entre rendimiento, robustez y adaptabilidad. El enfoque con k-NN, si bien limitado para clasificación directa en entornos abiertos, podría seguir siendo útil en tareas complementarias como la recuperación de imágenes similares, la búsqueda por contenido o como sistema de apoyo en análisis exploratorios.

7. Autoevaluación de cada miembro del equipo

Secciones		Nombre		
		Lucas M. Herencia Solís	Marina Calero López	Juan A. Moreno Moguel
Exposición	Compresión y dominio	Excelente	Regular	Bien
	Exposición didáctica	Excelente	Bien	Excelente
	Integración equipo	Excelente	Excelente	Excelente
Implementación	Objetivos	Excelente	Bien	Bien
	Aspectos didácticos	Excelente	Bien	Bien
	Experimentación y conclusión	Excelente	Excelente	Bien
Documentación	Contenidos	Excelente	Bien	Bien
	Divulgación de contenidos	Excelente	Excelente	Excelente
	Bibliografía / Recursos científicos	Excelente	Excelente	Excelente

Tabla 1: Evaluación del desempeño por secciones


8. Tabla de tiempos

Summary report

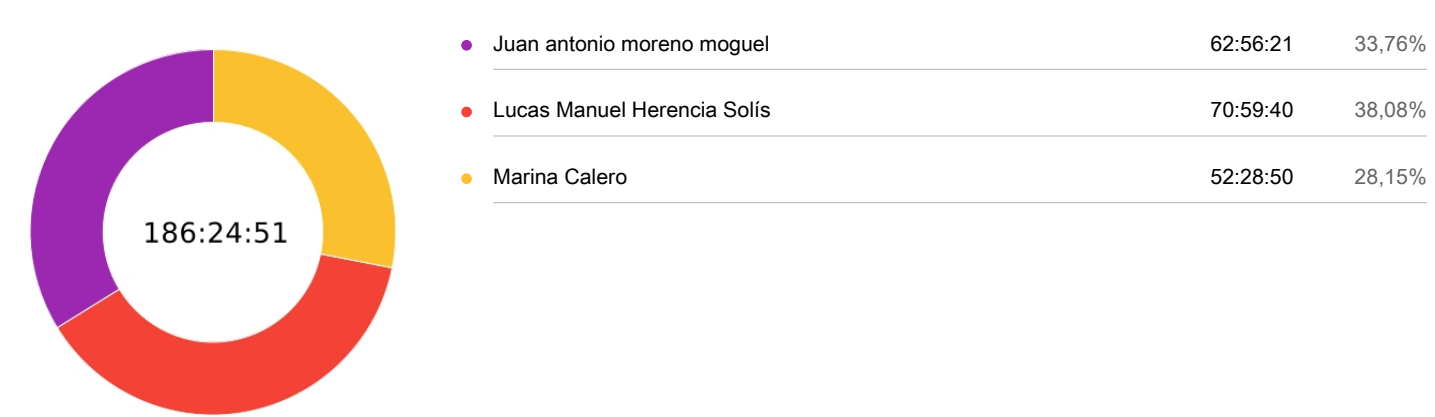
01/01/2025 - 31/12/2025



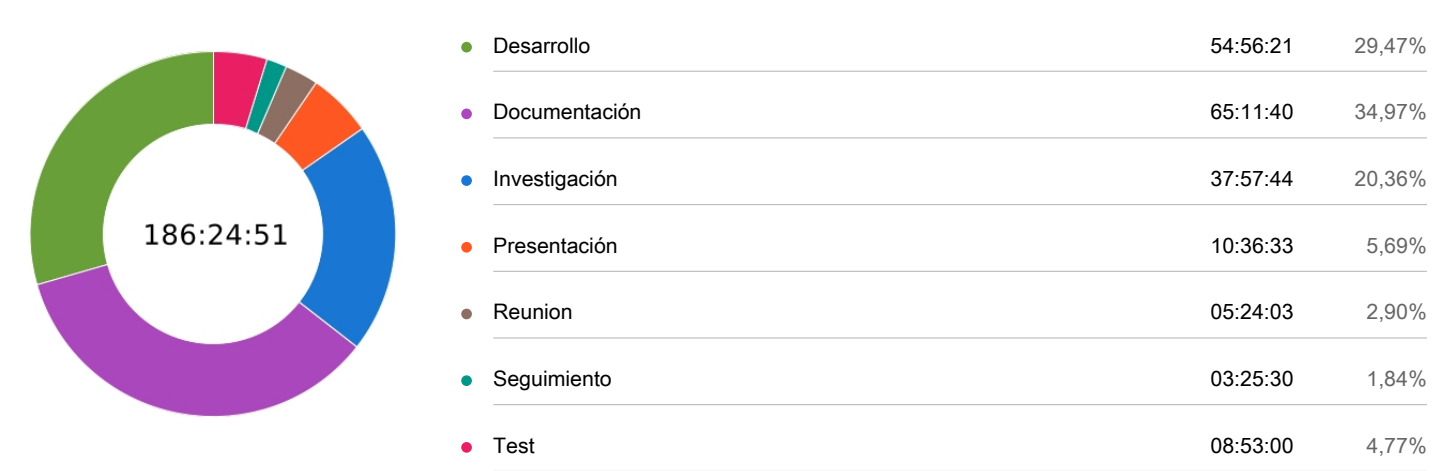
Total: 186:24:51



User



Project



User / Project	Duration
Juan antonio moreno moguel	62:56:21
Desarrollo	08:25:00
Documentación	27:33:21
Investigación	14:46:00
Presentación	02:49:00
Reunion	01:55:00
Seguimiento	01:07:00
Test	06:21:00
Lucas Manuel Herencia Solís	70:59:40
Desarrollo	29:35:00
Documentación	16:03:26
Investigación	18:33:14
Presentación	00:52:00
Reunion	01:57:00
Seguimiento	01:27:00
Test	02:32:00
Marina Calero	52:28:50
Desarrollo	16:56:21
Documentación	21:34:53
Investigación	04:38:30
Presentación	06:55:33
Reunion	01:32:03
Seguimiento	00:51:30

Detailed report

01/01/2025 - 31/12/2025

Total: 52:28:50



Date	Description	Duration	User
11/02/2025	investigar sobre el trabajo que vamos a realizar Investigación	01:12:44 11:03:00 - 12:15:44	Marina Calero
26/02/2025	Seguimiento 1 Seguimiento	00:10:30 08:53:00 - 09:03:30	Marina Calero
26/02/2025	Buscando información del dataset Investigación	01:05:07 09:14:53 - 10:20:00	Marina Calero
09/03/2025	Añadiendo resumen, extendiendo introducción, ponerlo todo con las mismas fuentes y poner el enlace de las referencias Documentación	00:52:58 18:08:52 - 19:01:50	Marina Calero
09/03/2025	Reunión 1 -> seguimiento del trabajo realizado Reunion	00:15:13 19:01:53 - 19:17:06	Marina Calero
09/03/2025	Redactar las herramientas a utilizar Documentación	01:07:34 19:17:09 - 20:24:43	Marina Calero
18/03/2025	Reescribiendo las herramientas del documento Documentación	00:07:23 11:24:15 - 11:31:38	Marina Calero
18/03/2025	Explicar el CNN y el SVM Documentación	00:54:31 11:31:44 - 12:26:15	Marina Calero
21/03/2025	Mejorar el css de Tkinter e intentar cargar los dataset del artículo Desarrollo	01:27:17 10:58:34 - 12:25:51	Marina Calero
25/03/2025	Intentando hacer que funcione el CNN Desarrollo	01:15:56 10:45:00 - 12:00:56	Marina Calero
25/03/2025	Consiguiendo mejor el entrenamiento Desarrollo	03:25:35 13:30:00 - 16:55:35	Marina Calero
25/03/2025	Mejorando el CNN Desarrollo	00:03:28 18:37:38 - 18:41:06	Marina Calero
26/03/2025	Investigando el código de otro repo Desarrollo	02:54:11 10:04:23 - 12:58:34	Marina Calero
01/04/2025	Mejorando la interfaz gráfica de Tkinter Desarrollo	03:55:41 13:39:19 - 17:35:00	Marina Calero

02/04/2025	Arreglando botón de pausa y reanudar de la interfaz Desarrollo	01:56:04 09:27:00 - 11:23:04	Marina Calero
08/04/2025	Leer documentación del repositorio encontrado Investigación	00:43:54 12:37:09 - 13:21:03	Marina Calero
08/04/2025	Actualizar la función de la interfaz Desarrollo	00:59:09 13:11:16 - 14:10:25	Marina Calero
09/04/2025	Reunión Segimiento 3 Seguimiento	00:22:00 08:56:00 - 09:18:00	Marina Calero
09/04/2025	Investigar la documentación del paper del repo encontrado Investigación	01:36:45 09:29:00 - 11:05:45	Marina Calero
22/04/2025	Explicación de los CNN y KNN Reunion	00:36:50 15:51:51 - 16:28:41	Marina Calero
28/04/2025	descargando modelos y haciendo presentación Presentación	03:26:48 11:10:43 - 14:37:31	Marina Calero
29/04/2025	Haciendo la presentación Presentación	03:28:45 14:52:00 - 18:20:45	Marina Calero
29/04/2025	Modificando el documento y añadiendo cosas al modelo Desarrollo	00:59:00 19:50:00 - 20:49:00	Marina Calero
30/04/2025	Seguimiento 4 Seguimiento	00:19:00 09:32:00 - 09:51:00	Marina Calero
30/04/2025	Reunión de alineamiento con el proyecto Reunion	00:40:00 10:30:00 - 11:10:00	Marina Calero
30/04/2025	Añadiendo el documento a latex Documentación	02:03:08 11:10:14 - 13:13:22	Marina Calero
30/04/2025	Pasando el documento al latex Documentación	04:35:57 13:52:30 - 18:28:27	Marina Calero
05/05/2025	Revisando el documento entero para ver que falta o que hay que quitar Documentación	03:00:27 18:00:00 - 21:00:27	Marina Calero
06/05/2025	Haciendo capturas de la interfaz de la aplicación he intentando añadirlas al documento latex Documentación	00:15:21 13:49:26 - 14:04:47	Marina Calero
10/05/2025	Modificando el documento Documentación	03:36:00 17:00:00 - 20:36:00	Marina Calero
11/05/2025	Añadiendo tablas, conclusiones e imagenes a la documentación de latex Documentación	01:43:40 12:20:00 - 14:03:40	Marina Calero

11/05/2025	Añadiendo tablas, conclusiones e imagenes a la documentación de latex	03:17:54	Marina Calero
	Documentación	15:03:00 - 18:20:54	

Detailed report

01/01/2025 - 31/12/2025

Total: 70:59:40



Date	Description	Duration	User
11/02/2025	Investigar sobre el trabajo que vamos a realizar Investigación	01:42:00 11:03:00 - 12:45:00	Lucas Manuel Herencia Solís
20/02/2025	Investigación sobre posibles estudios de clasificación de células cancerígenas Investigación	02:00:00 10:00:00 - 12:00:00	Lucas Manuel Herencia Solís
22/02/2025	Introducción de documento de seguimiento 1 Documentación	00:21:00 19:39:00 - 20:00:00	Lucas Manuel Herencia Solís
24/02/2025	Subir dataset de images a drive y poner en el README información sobre su descarga Documentación	00:13:00 00:10:00 - 00:23:00	Lucas Manuel Herencia Solís
25/02/2025	Revisión de documento de seguimiento Documentación	00:20:00 20:00:00 - 20:20:00	Lucas Manuel Herencia Solís
26/02/2025	Seguimiento 1 Seguimiento	00:10:00 08:53:00 - 09:03:00	Lucas Manuel Herencia Solís
26/02/2025	Lectura del documento elegido Investigación	00:33:14 09:36:46 - 10:10:00	Lucas Manuel Herencia Solís
09/03/2025	Interfaz de la app realizada con Tkinter Desarrollo	01:23:00 18:08:00 - 19:31:00	Lucas Manuel Herencia Solís
09/03/2025	Manual de usuario de la aplicación de escritorio Documentación	00:07:26 20:45:18 - 20:52:44	Lucas Manuel Herencia Solís
11/03/2025	Lectura de documento de investigación Investigación	00:30:00 10:30:00 - 11:00:00	Lucas Manuel Herencia Solís
11/03/2025	Implementación de red neuronal Desarrollo	01:30:00 11:00:00 - 12:30:00	Lucas Manuel Herencia Solís
11/03/2025	Arreglos en configuración de creación de dataset clasificados de entrenamiento y validación a partir de las imágenes Desarrollo	01:18:00 12:50:00 - 14:08:00	Lucas Manuel Herencia Solís
11/03/2025	Arreglos en la división de datos de entrenamiento para disminución de datos a elegir Desarrollo	01:06:00 18:45:00 - 19:51:00	Lucas Manuel Herencia Solís

12/03/2025	Seguimiento 2 Seguimiento	00:15:00 09:00:00 - 09:15:00	Lucas Manuel Herencia Solís
21/03/2025	Modificación en red neuronal Desarrollo	01:30:00 10:00:00 - 11:30:00	Lucas Manuel Herencia Solís
21/03/2025	Busqueda de modelo prehecho para clasificación de imágenes Investigación	00:30:00 11:30:00 - 12:00:00	Lucas Manuel Herencia Solís
26/03/2025	Busqueda e investigación de otros repositorios posibles para predicciones Investigación	03:30:00 09:30:00 - 13:00:00	Lucas Manuel Herencia Solís
26/03/2025	Implementación de modelo extraído de repositorio de github Desarrollo	01:00:00 13:00:00 - 14:00:00	Lucas Manuel Herencia Solís
01/04/2025	Investigación del modelo entrenado para ver significado de resultados Investigación	01:40:00 10:40:00 - 12:20:00	Lucas Manuel Herencia Solís
01/04/2025	Implementación de nuevo entrenamiento en interfaz Desarrollo	00:20:00 12:20:00 - 12:40:00	Lucas Manuel Herencia Solís
01/04/2025	Investigación de posibles problemas que se produzcan a la hora de realizar las predicciones Investigación	01:34:00 17:20:00 - 18:54:00	Lucas Manuel Herencia Solís
02/04/2025	Arreglos a la hora de realizar clasificación de modelo con IA Desarrollo	03:14:00 09:00:00 - 12:14:00	Lucas Manuel Herencia Solís
08/04/2025	Refactorización de código para eliminar código sin uso Desarrollo	01:00:00 10:30:00 - 11:30:00	Lucas Manuel Herencia Solís
08/04/2025	Investigación de como funciona la clasificación del modelo entrenado Investigación	01:00:00 11:30:00 - 12:30:00	Lucas Manuel Herencia Solís
08/04/2025	Cambios en la función de predicción para que analice un solo archivo y devuelva el color Desarrollo	00:40:00 13:00:00 - 13:40:00	Lucas Manuel Herencia Solís
09/04/2025	Seguimiento 3 Seguimiento	00:22:00 08:58:00 - 09:20:00	Lucas Manuel Herencia Solís
09/04/2025	Representación a través de una gráfica de las características de la imagen Desarrollo	00:49:00 10:30:00 - 11:19:00	Lucas Manuel Herencia Solís
21/04/2025	Lectura del nuevo documento de investigación Investigación	02:14:00 14:30:00 - 16:44:00	Lucas Manuel Herencia Solís
21/04/2025	Lectura del primer documento elegido de investigación Investigación	01:26:00 16:44:00 - 18:10:00	Lucas Manuel Herencia Solís

21/04/2025	Realización de código y entrenamiento de modelos especializados y general de CNN Desarrollo	03:12:00 21:00:00 - 00:12:00 ⁺¹	Lucas Manuel Herencia Solís
22/04/2025	Implementación de cnn corregido y posibilidad de escoger de cnn entrenado con todas las imágenes o específico para cierta magnificencia Desarrollo	02:30:00 00:12:00 - 02:42:00	Lucas Manuel Herencia Solís
22/04/2025	Modificación en código para limpieza y separación en diferentes archivos de pruebas Desarrollo	00:40:00 10:30:00 - 11:10:00	Lucas Manuel Herencia Solís
22/04/2025	Preguntas sobre el proyecto en su estado actual en clase Reunion	00:40:00 11:10:00 - 11:50:00	Lucas Manuel Herencia Solís
22/04/2025	Investigación de como funciona el autoencoder respecto a la extracción de características Investigación	00:30:00 11:50:00 - 12:20:00	Lucas Manuel Herencia Solís
22/04/2025	Explicar de los CNN y KNN Reunion	00:37:00 15:51:00 - 16:28:00	Lucas Manuel Herencia Solís
29/04/2025	Correcciones en uso de knn para posterior experimentación Desarrollo	03:00:00 10:00:00 - 13:00:00	Lucas Manuel Herencia Solís
29/04/2025	Arreglos en knn y funciones de testeo sobre data augmentation Desarrollo	01:00:00 14:30:00 - 15:30:00	Lucas Manuel Herencia Solís
30/04/2025	Realizar documento de seguimiento Seguimiento	00:21:00 00:10:00 - 00:31:00	Lucas Manuel Herencia Solís
30/04/2025	Seguimiento 4 Seguimiento	00:19:00 09:32:00 - 09:51:00	Lucas Manuel Herencia Solís
30/04/2025	Explicación del proyecto Reunion	00:40:00 10:30:00 - 11:10:00	Lucas Manuel Herencia Solís
30/04/2025	Cambio para uso de pesos en ver de carga de modelo completo Desarrollo	02:30:00 11:40:00 - 14:10:00	Lucas Manuel Herencia Solís
30/04/2025	Cambiar para que las métricas se guarden en un csv en vez de en un txt Desarrollo	01:45:00 14:25:00 - 16:10:00	Lucas Manuel Herencia Solís
30/04/2025	Investigar como funciona el método de visualización creado de características Investigación	00:37:00 16:20:00 - 16:57:00	Lucas Manuel Herencia Solís
04/05/2025	Añadir pruebas para knn con data augmentation Test	01:21:00 17:00:00 - 18:21:00	Lucas Manuel Herencia Solís
04/05/2025	Reestructuración de muestra de métricas de la experimentación Test	01:11:00 18:21:00 - 19:32:00	Lucas Manuel Herencia Solís

04/05/2025	Añadir archivos de pesos Desarrollo	00:03:00 19:32:00 - 19:35:00	Lucas Manuel Herencia Solís
04/05/2025	Extracción de requirements.txt con dependencias necesarias Desarrollo	01:05:00 19:35:00 - 20:40:00	Lucas Manuel Herencia Solís
04/05/2025	Revisión de documentación y README.md Documentación	03:22:00 20:40:00 - 00:02:00 ⁺¹	Lucas Manuel Herencia Solís
05/05/2025	Correcciones en el documento Documentación	02:10:00 12:20:00 - 14:30:00	Lucas Manuel Herencia Solís
05/05/2025	Editar documentación de manual de usuario Documentación	00:24:00 14:40:00 - 15:04:00	Lucas Manuel Herencia Solís
05/05/2025	Evaluar y añadir tabla al documento Documentación	00:04:00 15:04:00 - 15:08:00	Lucas Manuel Herencia Solís
05/05/2025	Grabación de video de implementación Documentación	00:52:00 15:08:00 - 16:00:00	Lucas Manuel Herencia Solís
05/05/2025	Grabación de video de demo Presentación	00:52:00 16:00:00 - 16:52:00	Lucas Manuel Herencia Solís
05/05/2025	Investigación de otros posibles dataset para uso de imágenes en experimentación Investigación	00:47:00 16:52:00 - 17:39:00	Lucas Manuel Herencia Solís
05/05/2025	Edición de videos Documentación	02:26:00 18:10:00 - 20:36:00	Lucas Manuel Herencia Solís
05/05/2025	Vídeo de explicación de experimentación Documentación	00:40:00 23:30:00 - 00:10:00 ⁺¹	Lucas Manuel Herencia Solís
06/05/2025	Documentación del código Documentación	04:13:00 18:00:00 - 22:13:00	Lucas Manuel Herencia Solís
10/05/2025	Cambios en README.md para dejar mejores declaraciones de los pasos a realizar Documentación	00:51:00 15:50:00 - 16:41:00	Lucas Manuel Herencia Solís

Detailed report

01/01/2025 - 31/12/2025

Total: 62:56:21



Date	Description	Duration	User
19/02/2025	Búsqueda de datasets con células cancerígenas Investigación	00:14:09 08:32:00 - 08:46:09	Juan antonio moreno moguel
19/02/2025	Selección final de dataset y búsqueda de información sobre tipo de cáncer a investigar Investigación	02:25:00 10:30:00 - 12:55:00	Juan antonio moreno moguel
26/02/2025	Seguimiento 1 Seguimiento	00:10:00 08:53:00 - 09:03:00	Juan antonio moreno moguel
26/02/2025	Lectura referencia inicial Investigación	01:00:06 09:19:54 - 10:20:00	Juan antonio moreno moguel
03/03/2025	Busqueda de mas referencias Investigación	03:14:45 10:00:00 - 13:14:45	Juan antonio moreno moguel
05/03/2025	Documentar referencias encontradas e Introducción Documentación	02:22:21 09:30:00 - 11:52:21	Juan antonio moreno moguel
09/03/2025	Reunion 1: Seguimiento del trabajo realizado Reunion	00:15:00 19:02:00 - 19:17:00	Juan antonio moreno moguel
12/03/2025	Seguimiento 2 Seguimiento	00:15:00 09:00:00 - 09:15:00	Juan antonio moreno moguel
25/03/2025	Desarrollo de código de test de modelo Desarrollo	03:25:00 13:30:00 - 16:55:00	Juan antonio moreno moguel
26/03/2025	Busqueda de papers, se ha encontrado uno bastante bueno para usar Investigación	03:13:00 08:10:00 - 11:23:00	Juan antonio moreno moguel
26/03/2025	Desarrollo del modelo, cambio de repositorio Desarrollo	05:00:00 09:30:40 - 14:30:40	Juan antonio moreno moguel
09/04/2025	Seguimiento 3 Seguimiento	00:23:00 10:55:00 - 11:18:00	Juan antonio moreno moguel
20/04/2025	Explicar implementación del modelo Documentación	03:33:00 16:22:00 - 19:55:00	Juan antonio moreno moguel

22/04/2025	Reunion de equipo para repartir tareas (yo tengo el analisis, tanto hacerlo como documentarlo) Reunion	01:00:00 12:00:00 - 13:00:00	Juan antonio moreno moguel
29/04/2025	Arreglar el entorno y realizar el analisis de los tests realizados creando un documento que genere graficas (aun no funciona) Test	03:30:00 17:30:00 - 21:00:00	Juan antonio moreno moguel
30/04/2025	Realizar borrador de metodologia del proyecto Documentación	02:22:00 00:00:00 - 02:22:00	Juan antonio moreno moguel
30/04/2025	Seguimiento 4 Seguimiento	00:19:00 09:32:00 - 09:51:00	Juan antonio moreno moguel
30/04/2025	Reunion de alineamiento con el proyecto Reunion	00:40:00 10:30:00 - 11:10:00	Juan antonio moreno moguel
30/04/2025	Relectura del documento de la arquitectura CNN para propia documentacion Investigación	00:55:00 11:20:00 - 12:15:00	Juan antonio moreno moguel
30/04/2025	Reformulación de introducción y planteamiento teórico Documentación	00:35:00 12:15:00 - 12:50:00	Juan antonio moreno moguel
30/04/2025	Documentación de la arquitectura de la aplicación, CNN y KNN Documentación	01:35:00 12:50:00 - 14:25:00	Juan antonio moreno moguel
03/05/2025	Mostrar graficas coherentes Test	02:51:00 18:00:00 - 20:51:00	Juan antonio moreno moguel
04/05/2025	Mejorar las graficas y elegir las graficas finales Documentación	01:15:00 17:30:00 - 18:45:00	Juan antonio moreno moguel
06/05/2025	Analizar las graficas de las metricas Investigación	03:44:00 09:06:00 - 12:50:00	Juan antonio moreno moguel
06/05/2025	Añadir graficas a la presentacion y datos al readme Documentación	00:45:00 12:50:00 - 13:35:00	Juan antonio moreno moguel
06/05/2025	Poner las imagenes en el documento (falta la explicacion del documento y correccion de fallos) Documentación	00:49:00 15:40:00 - 16:29:00	Juan antonio moreno moguel
09/05/2025	Redaccion de los tests realizados en el documento Documentación	02:25:00 10:00:00 - 12:25:00	Juan antonio moreno moguel
10/05/2025	Reestructuracion y arreglo del documento, actualizar referencias y mejorar legibilidad Documentación	04:22:00 10:15:00 - 14:37:00	Juan antonio moreno moguel
10/05/2025	Reestructuracion y arreglo del documento, actualizar referencias y mejorar legibilidad Documentación	05:30:00 15:00:00 - 20:30:00	Juan antonio moreno moguel

11/05/2025	<p>Escribir la conclusion, rehacer la experimentación y poner las cosas en latex</p> <p>Documentación</p>	<p>02:00:00</p> <p>14:00:00 - 16:00:00</p>	Juan antonio moreno moguel
11/05/2025	<p>Hacer las conclusiones, metricas y planteamiento teorico en la presentacion</p> <p>Presentación</p>	<p>01:00:00</p> <p>16:00:00 - 17:00:00</p>	Juan antonio moreno moguel
11/05/2025	<p>Guion de la presentación de la parte de experimentacion y conclusiones</p> <p>Presentación</p>	<p>01:49:00</p> <p>18:20:00 - 20:09:00</p>	Juan antonio moreno moguel

Referencias

- [1] World Health Organization, «Breast Cancer,» 2025, Accessed: 2025-04-30.
- [2] P. P. Shinde y S. Shah, «A review of machine learning and deep learning applications,» págs. 1-6, 2018.
- [3] D. Bardou, K. Zhang y S. M. Ahmad, «Classification of breast cancer based on histology images using convolutional neural networks,» *Ieee Access*, vol. 6, págs. 24 680-24 693, 2018.
- [4] Python Software Foundation, «Welcome to Python.org,» 2023, Accessed: 2023-11-15. dirección: <https://www.python.org/>.
- [5] Python Software Foundation, «Tkinter — Python interface to Tcl/Tk,» es, nov. de 2023, Versión 3.x, consultado el 2023-11-15. dirección: <https://docs.python.org/es/3/library/tkinter.html>.
- [6] Google Brain Team and TensorFlow contributors, «TensorFlow: An end-to-end open source platform for machine learning,» 2023, Accessed: 2023-11-15. dirección: <https://www.tensorflow.org/>.
- [7] DataCamp, «Capas convoluciones: CNN con TensorFlow en Python,» 2025, Accessed: 2025-04-30.
- [8] Y. LeCun, L. Bottou, Y. Bengio y P. Haffner, «Gradient-based learning applied to document recognition,» *Proceedings of the IEEE*, vol. 86, n.º 11, págs. 2278-2324, 1998.
- [9] V. Nair y G. E. Hinton, «Rectified linear units improve restricted boltzmann machines,» págs. 807-814, 2010.
- [10] A. L. Maas, A. Y. Hannun, A. Y. Ng et al., «Rectifier nonlinearities improve neural network acoustic models,» vol. 30, n.º 1, pág. 3, 2013.
- [11] P. Sermanet, D. Eigen, X. Zhang, M. Mathieu, R. Fergus e Y. LeCun, «Overfeat: Integrated recognition, localization and detection using convolutional networks,» *arXiv preprint arXiv:1312.6229*, 2013.
- [12] C. M. Bishop y N. M. Nasrabadi, «Pattern recognition and machine learning,» vol. 4, n.º 4, 2006.
- [13] D. P. Kingma y J. Ba, «Adam: A method for stochastic optimization,» *arXiv preprint arXiv:1412.6980*, 2014.
- [14] D. E. Rumelhart, G. E. Hinton y R. J. Williams, «Learning representations by back-propagating errors,» *nature*, vol. 323, n.º 6088, págs. 533-536, 1986.
- [15] D. Bank, N. Koenigstein y R. Giryes, «Autoencoders,» *Machine learning for data science handbook: data mining and knowledge discovery handbook*, págs. 353-374, 2023.
- [16] J. Masci, U. Meier, D. Cireşan y J. Schmidhuber, «Stacked convolutional autoencoders for hierarchical feature extraction,» págs. 52-59, 2011.
- [17] G. E. Hinton y R. R. Salakhutdinov, «Reducing the dimensionality of data with neural networks,» *science*, vol. 313, n.º 5786, págs. 504-507, 2006.
- [18] I. Goodfellow, Y. Bengio, A. Courville e Y. Bengio, «Deep learning,» vol. 1, n.º 2, 2016.

- [19] Janosh, «Autoencoder Diagram,» 2023, Accessed: [Insert Date Here]. dirección: <https://tikz.net/janosh/autoencoder.png>.
- [20] T. Cover y P. Hart, «Nearest neighbor pattern classification,» *IEEE transactions on information theory*, vol. 13, n.º 1, págs. 21-27, 1967.
- [21] K. Chomboon, P. Chujai, P. Teerarassamee, K. Kerdprasop y N. Kerdprasop, «An empirical study of distance metrics for k-nearest neighbor algorithm,» vol. 2, pág. 4, 2015.
- [22] M. Archive, «K-Nearest Neighbor (KNN) Explained,» 2023, Machine Learning Archive. visitado 15 de nov. de 2023. dirección: <https://mlarchive.com/machine-learning/k-nearest-neighbor-knn-explained/>.
- [23] L. Van Der Maaten, E. O. Postma, H. J. Van Den Herik et al., «Dimensionality reduction: A comparative review,» *Journal of machine learning research*, vol. 10, n.º 66-71, pág. 13, 2009.
- [24] Y. Bengio, A. Courville y P. Vincent, «Representation learning: A review and new perspectives,» *IEEE transactions on pattern analysis and machine intelligence*, vol. 35, n.º 8, págs. 1798-1828, 2013.
- [25] C. C. Aggarwal y C. K. Reddy, «Data clustering,» *Algorithms and applications. Chapman&Hall/CRC Data mining and Knowledge Discovery series, Londra*, 2014.
- [26] Google Drive, «Carpeta compartida de recursos,» 2025, Accessed: 2025-04-30.
- [27] F. A. Spanhol, L. S. Oliveira, C. Petitjean y L. Heutte, «A dataset for breast cancer histopathological image classification,» *Ieee transactions on biomedical engineering*, vol. 63, n.º 7, págs. 1455-1462, 2015.
- [28] A. E. Minarno, K. M. Ghufon, T. S. Sabrila, L. Husniah y F. D. S. Sumadi, «Cnn based autoencoder application in breast cancer image retrieval,» págs. 29-34, 2021.